

Méthodologie

Notre idée centrale est de porter l'analyse sur la différence entre les deux journaux et leur évolution dans le temps. La méthodologie détaillée en dessous sera donc appliquée sur les deux journaux séparément et elle sera organisée en 3 catégories.

- La présentation des articles
- Le contexte des articles
- Le contenu des articles

Le schéma en dessous détaille les outils que nous voulons utiliser pour obtenir toutes les données pour notre analyse :

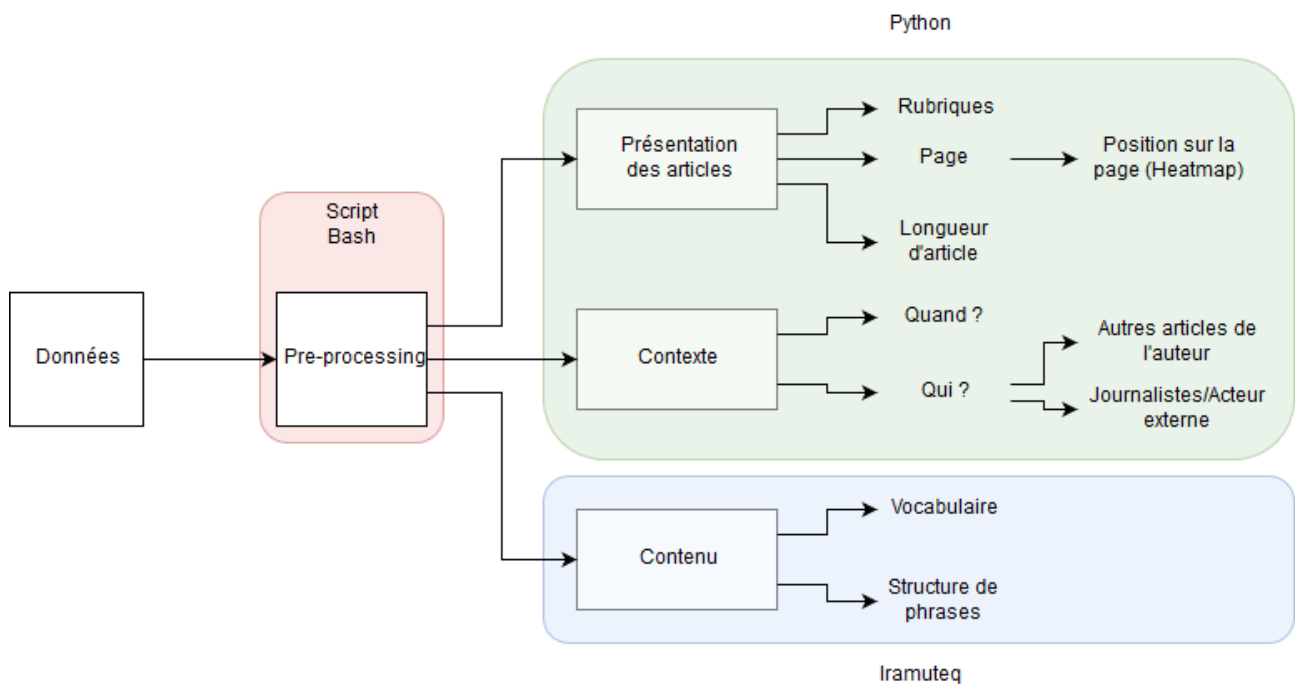


FIGURE 1 – Graphique résumant toute la méthodologie.

Pre-processing

À fin de pouvoir conduire notre analyse, nous devons réduire le corpus pour l'explorer de manière plus rapide et interactive. Le corpus de base se constitue de tous les articles de la *Gazette de Lausanne* et du *Journal de Genève* sortis entre 1900 et 1999. Les données nous parviennent compressées en format `bzip2` et occupent en total 18 Go sur le disque. Si les données sont décompressées, le volume s'augmente d'un facteur dix. Ceci nous cause un problème, car plus que 200 Go de données ne rentrent pas dans la mémoire RAM d'un ordinateur, limitant les méthodes de questionnement que nous pouvons appliquer.

Pour résoudre ce problème, nous pourrions opérer sur les données en les décompressant au moment du besoin. Cette approche est raisonnable, mais elle introduit de longs temps d'élaboration.

Effectivement, le format **bzip2** permet une forte réduction de la taille des fichiers, mais à un coût d'un long temps de décompression. Une expérience confirme que pour chercher les mots "secret bancaire" dans un fichier **bzip2** contenant les articles du *Journal de Genève* de 1970, la décompression nécessite 24.1s alors que le temps de recherche est de 0.6s. Pour cette raison nous travaillerons sur un sous-ensemble des données décompressées à l'avance. Mais, nous souhaitons ne pas limiter notre corpus aux articles qui contiennent un des mots clés, car les autres articles nous seront utiles pour effectuer d'autres analyses, comme par exemple trouver tous les articles écrits par un certain auteur. Le problème consiste donc en réduire les 200 Go de données brutes pour les stocker et manipuler aisément.

Pour cela, nous ignorons les méta-données sur la position des mots sur la page qui occupent environ 90% du volume et ne sont pas nécessaires à nos analyses. Nous les gardons seulement pour les quelques articles qui contiennent un de nos mots clés. De cette façon, nous travaillons avec un total d'environ 9 Go de données décompressées. Une recherche par mots clés passe ainsi de 1h30 sur les données compressées à une minute sur les données nettoyées et décompressées.

Analyse de la présentation

Nous cherchons à comprendre et comparer la façon dont le sujet du secret bancaire suisse est abordé dans les deux journaux. Cela pose la question de la présentation des articles. À quelle page peut-on trouver les articles ? Cette question nous permettra d'évaluer l'importance du sujet pour les deux journaux, en regardant si le sujet occupe la première ou s'il est dans les ultérieures. Nous voudrions aussi créer une *heatmap*¹ de la position des articles sur la page, afin de voir si les articles se trouvent, par exemple, toujours en haut de la page. En plus, nous vérifierons si les articles sur le secret bancaire font parti d'une rubrique récurrente ou non. Finalement, nous évaluerons la longueur des articles, un long article indiquant que le sujet est perçu comme important par la rédaction.

Analyse du contexte

Le contexte d'un article inclut le date de publication. Celle-ci est la méta-donnée la plus importante, car elle peut facilement être mise en relation avec l'évolution du sujet.

La deuxième méta-donnée centrale est l'auteur ? Nous voulons séparer en deux les possibles acteurs.

- **Journalistes** : Nous essayerons de mettre en perspective l'activité d'un journaliste. Est-ce un journaliste généraliste ou spécialisé ? Quelles sont les thématiques de ses autres articles ? De quand à quand est-il actif ?
- **Auteurs externes** : Est-ce que l'auteur s'exprime au nom d'une institution comme par exemple une banque ou est-ce un représentant politique ? Quel est le contexte de l'intervention médiatique pour cette institution ?

1. Une *heatmap*, en français "carte de chaleur", est une graphique qui indique la fréquence ou l'intensité de la donnée à chaque position dans un cadre défini.

Analyse du contenu

Dernièrement, nous allons nous intéresser aux articles directement. Cependant nous allons nous arrêter à des observations objectives. L'idée étant d'utiliser *Iramuteq* pour faire ressortir la structure des phrases et la distribution des mots. Ainsi, nous mettrons en lumière la différence entre le vocabulaire employé par les deux journaux afin de voir s'ils sont sur une couverture complètement factuelle ou non ? Nous voulons aussi tenter d'analyser le type de mot utilisé par les deux journaux. Toutes ces analyses ont pour but de ressortir les différences entre la manière dont les deux journaux parlent du sujet du secret bancaire suisse.