

Méthodologie

Notre idée centrale est de porter l'analyse sur la différence entre les deux journaux et leur évolution dans le temps. La méthodologie détaillée ici est donc appliquée sur les deux journaux séparément et elle est organisée en trois catégories.

- La présentation des articles
- Le contexte des articles
- Le contenu des articles

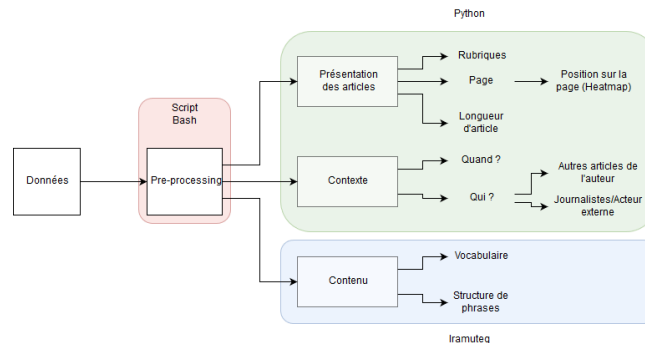


FIGURE 1 – Le schéma montre les outils que nous utilisons dans notre analyse.

Pre-processing

Pour notre analyse, nous devons réduire le corpus pour l'explorer de manière plus rapide. Le corpus de base se constitue de tous les articles de la *Gazette de Lausanne* (*GDL*) et du *Journal de Genève* (*JDG*) sortis entre 1900 et 1999. Les données nous parviennent compressées en format **bzip2** et occupent en total 18 Go sur le disque. Nous créons trois sous-corpus. Le plus grand est constitué de tous les articles, décompressés et sans méta-données concernant la position des mots dans l'article. Nous nous servons de ce corpus-là pour des questions qui regardent l'entièreté des journaux, comme la longueur en page du journal à une certaine date. Le deuxième corpus se limite aux articles de caractère financier et est extrait du premier corpus par la recherche des mots clés suivants :

- secret bancaire
- place financière
- banques suisses
- forfait fiscal
- paradis fiscal
- affaire Chiasso
- argent sale
- blanchiment

Nous utilisons ce corpus, qui est constitué de ~35'000 articles, pour nous comparer avec notre troisième corpus, sélectionné par le seul mot clé *secret bancaire*, contenant environ 1700 articles.

De cette façon, nous pouvons déterminer si une certaine tendance de ce corpus est vraiment significative, ou si elle apparaît dans tout le corpus financier.

Statistiques de base

Pour s’approcher à l’analyse des articles, nous commençons en calculant certaines statistiques de base, telles que le numéro de page, la longueur et la date. Nous reproduisons donc le N-Gram dans le temps, pour les articles contenant “secret bancaire” par année.

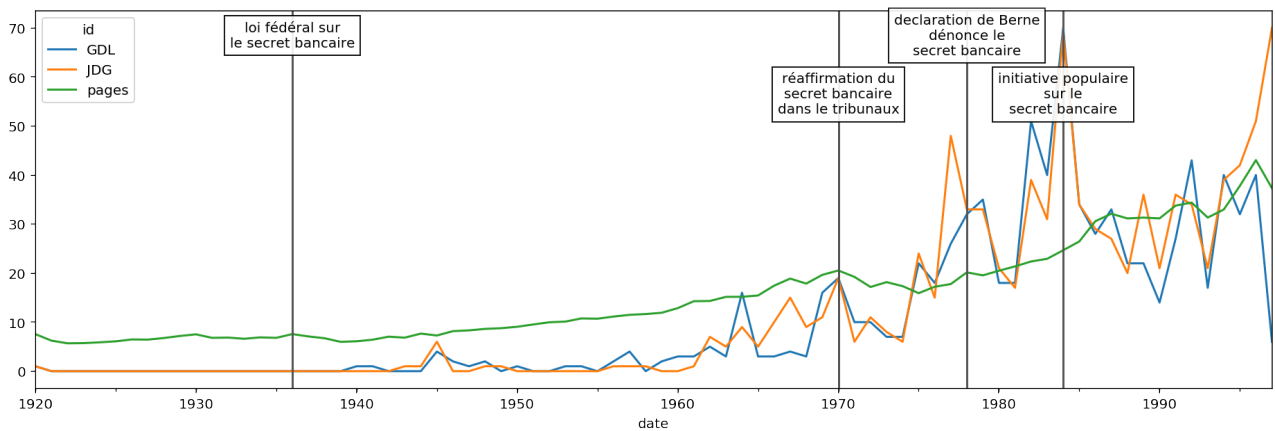


FIGURE 2 – Apparitions du terme “secret bancaire” dans les deux journaux au cours du temps

Ensuite, nous comparons la longueur d’un article sur le secret bancaire aux articles génériques du corpus financier. Nous pouvons constater en regardant l’histogramme suivant que les articles sur le secret bancaire, dans les deux journaux, sont en général un peu plus longs que les articles de finance génériques.




FIGURE 3 – Distribution de la longueur des articles

Nous examinons aussi, à l’aide d’un histogramme de la page de l’article, la distribution des positions des articles sur le secret bancaire. Pour mieux interpréter les résultats de cette analyse, nous trouvons la longueur du journal pour chaque date et calculons ainsi la position relative de l’article dans le journal. Nous cherchons enfin à voir si des rubriques spécialisées traitent le

sujet, en examinant des nuages de points corrélants la date et la page des articles en question. Des ligne horizontales isolées constituerait un indice d’une rubrique permanente qui traite le sujet à une page spécifique.




FIGURE 4 – Nuage de point de page de l’article dans le temps sur les deux journaux

En comparant le nombre d’article en première page, nous constatons que la fréquence d’une première page pour un article sur le secret bancaire est de 5% dans la *GDL* et 6% dans le *JDG*. En comparaison, la fréquence d’une première page pour un article générique financier est de 2% pour la *GDL* et 3% pour la *JDG*.

Analyse des auteurs

La méta-donnée la plus importante après la date qui est traitée en haut est l’auteur d’un article. Nous analysons deux catégories d’auteurs.

Agences de presse

Beaucoup d’articles de journal proviennent d’agences de presse externes à la rédaction. Nous classifions les articles des agences suivantes :

- ATS : Agence télégraphique suisse
- AFP : Agence France-Presse
- Reuters
- AP : Associated press

En comptant tous les articles qui sont issu d’une agence dans le corpus financier et dans le sous-corpus “secret bancaire”, nous trouvons que pour les articles du secret bancaire le taux d’articles issus d’agences est 10% plus haut que dans le corpus financier.

Journalistes

Même si l’auteur d’un article n’est pas toujours indiqué – surtout dans la première moitié du siècle – nous arrivons à extraire des données sur les journalistes. Au moyen d’une liste de noms d’auteurs¹ et des initiales qui sont utilisé pour signer un article, nous pouvons attribuer des auteurs à plus que 2600 articles. Le graphe en-bas montre leurs distribution dans le temps.




FIGURE 5 – Articles avec auteur attribué

Cette attribution nous permet de tenter de répondre aux questions suivantes : Est-ce un journaliste actif dans les deux journaux en même temps ? Est-ce qu’il écrit en moyenne plus souvent sur le secret bancaire que sur d’autres sujets ? De quand à quand est-il actif ?

Comme exemple, voici les trois auteurs du *JDG* qui ont écrit le plus sur le secret bancaire : Jean-Luc Lederrey (41 articles), Jacques-Simon Eggly (29 articles) et Sylvie Arsever (18 articles). Les deux premiers sont aussi très actifs dans la *GDL* et cela même avant la fusion des rédactions en 1991. En plus, une recherche LinkedIn ou Wikipédia révèle que les deux étaient actifs dans le monde bancaire² ou dans la politique libérale³.

Analyse du contenu

L’analyse de contenu se limite au corpus “secret bancaire”. Dans un premier temps nous produisons des graphiques d’analyses de similitudes pour les deux journaux :

→ expliquer ce que tu fais

Analyses de similitudes dans la Gazette de Lausanne

Analyses de similitudes dans le Journal de Genève

1. Cette liste était obtenue de la page [Wikipédia du Journal de Genève](#).
2. [Jean-Luc Lederrey sur LinkedIn](#).
3. [Jean-Simon Eggly sur Wikipédia](#).

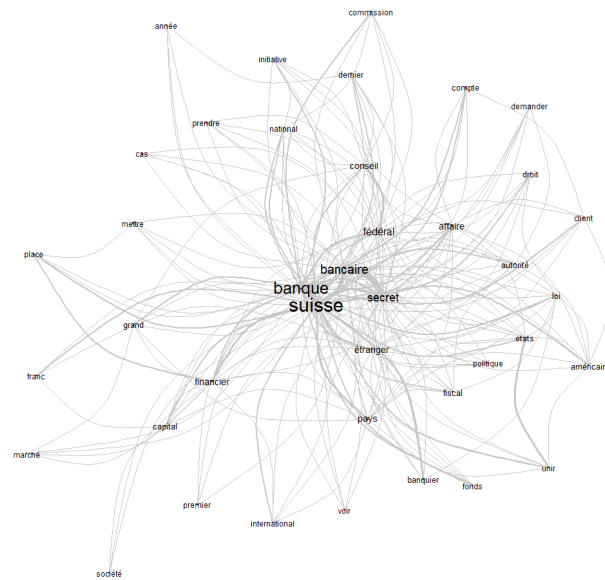


FIGURE 6 – SimilitudesGdL

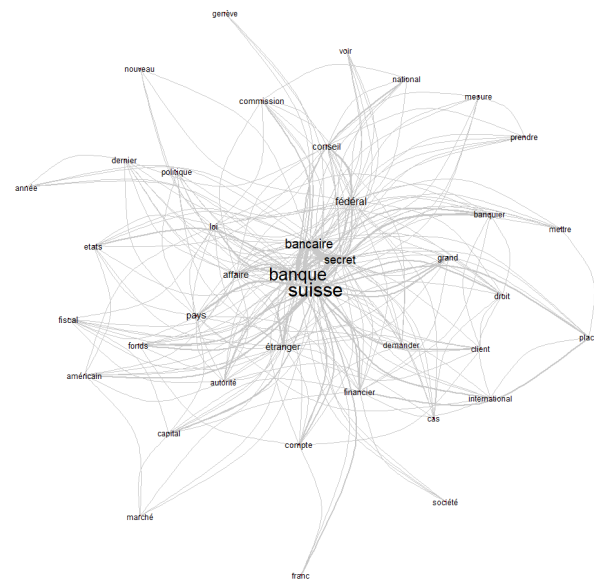


FIGURE 7 – SimilitudesGdL

→ expliquer ce qu'on voit

Afin de rendre les visuels utilisables, nous affichons ici seulement les 40 mots (autres que préposition et déterminants), de la même façon seuls les termes qui apparaissent plus de 50 fois ensemble sont montrés.

En suite, toujours dans un esprit de comparaison des journaux, nous produisons 2 dendrogrammes sur les journaux.

Dendrogramme de la Gazette de Lausanne

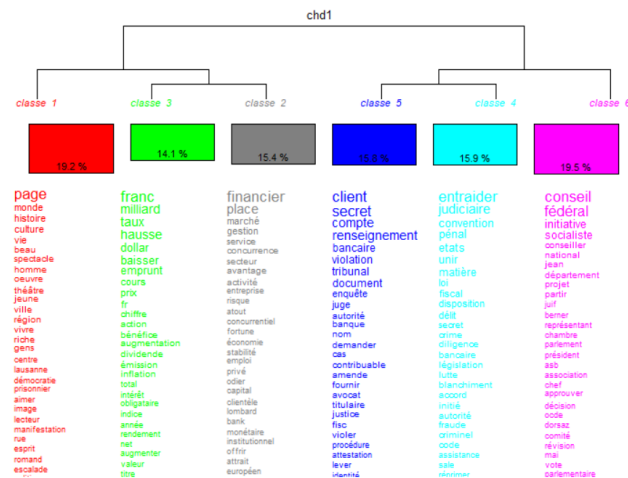


FIGURE 8 – DandrogramGdl

Dendrogramme du Journal de Genève

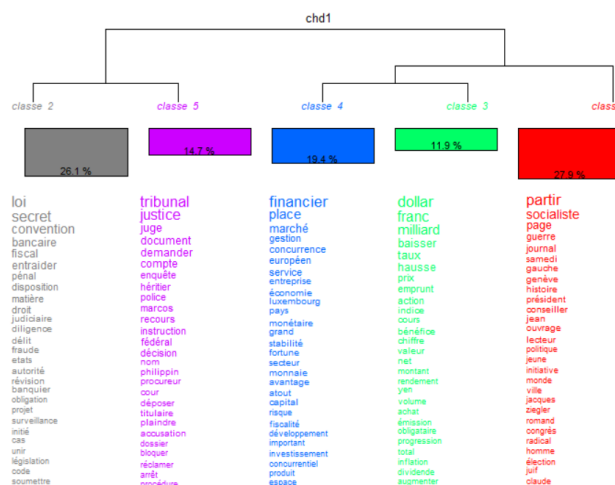


FIGURE 9 – DandrogramJdG

Après ces deux étapes nous percevons déjà de larges différences entre les deux journaux. -> comme quoi ?

Critique et difficultés

Notre analyse est particulièrement perturbée par les problèmes de l'OCR de basse qualité. Car, les termes que nous tentons d'isoler sont plutôt long une erreur de reconnaissance est bien plus probable.

Un autre problème est que le format de reconnaissance des articles est assez limité. Il a fallu que nous allions chercher le nom des auteurs manuellement, cependant nous avons observé que mettre le nom de l'auteur sur un article de journal ne deviens courant qu'à partir des années 60, limitant nos capacité d'analyse avant cette période.

Nous avons réussi à contourner ce problème en utilisant une liste de noms de journalistes ayant travaillé pour le *JDG*. Cependant nous ne trouvons pas de telle liste pour la *GDL*.