

## Méthodologie

Notre idée centrale est de porter l'analyse sur la différence entre les deux journaux et leur évolution dans le temps. La méthodologie détaillée ici est donc appliquée sur les deux journaux séparément et elle est organisée de manière suivante :

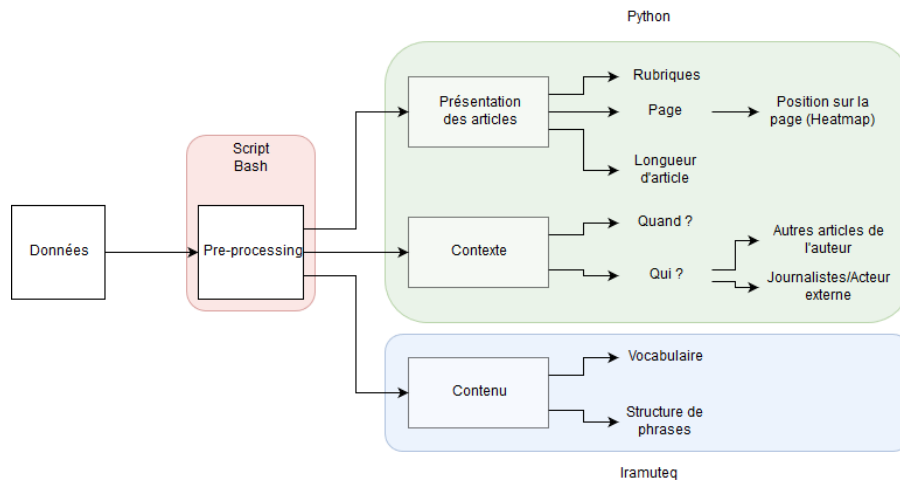


FIGURE 1 – Organisation et outils de l'analyse.

## Pre-processing

Pour l'explorer de manière plus rapide, nous devons réduire le corpus de base qui se constitue des articles de la *Gazette de Lausanne* (*GDL*) et du *Journal de Genève* (*JDG*) sortis entre 1900 et 1999.

Nous créons trois corpus. Le plus grand est constitué de tous les articles, décompressés (du format **bzip2**) et sans méta-données concernant la position des mots sur la page. Nous nous servons de ce corpus-là pour des questions qui regardent l'entièreté des journaux, comme la longueur en page du journal à une certaine date.

Le deuxième corpus se limite aux articles de caractère financier et est extrait du premier corpus par la recherche des mots clés suivants :

- secret bancaire
- place financière
- banques suisses
- forfait fiscal
- paradis fiscal
- affaire Chiasso
- argent sale
- blanchiment

Nous utilisons ce corpus de ~35'000 articles pour nous comparer avec notre troisième corpus, sélectionné par le seul mot clé “secret bancaire”, contenant environ 1700 articles. De cette façon, nous pouvons déterminer si une certaine tendance de ce corpus est vraiment signifiante, ou si elle apparaît dans tout le corpus financier.

## Statistiques de base

Nous commençons en calculant certaines statistiques de base, telles que le numéro de page, la longueur et la date d'un article. Nous reproduisons donc le N-Gram dans le temps, pour les articles contenant “secret bancaire” par année.




FIGURE 2 – Apparitions du terme “secret bancaire” dans les deux journaux au cours du temps

Ensuite, nous comparons la longueur d'un article sur le secret bancaire aux articles génériques du corpus financier. Nous pouvons constater en regardant l'histogramme suivant que les articles sur le secret bancaire, dans les deux journaux, sont en général un peu plus longs.

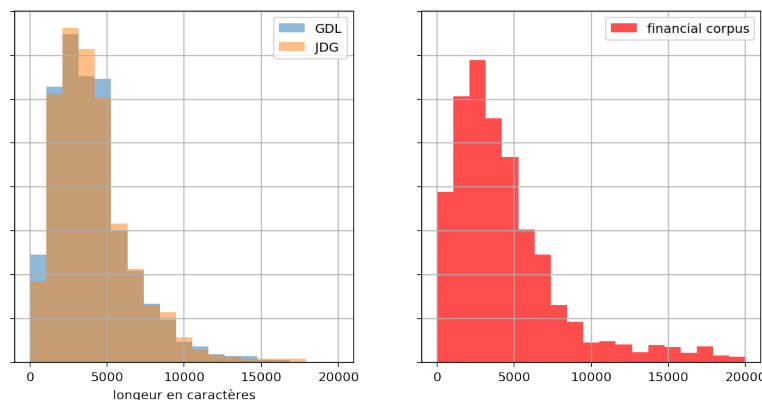


FIGURE 3 – Distribution de la longueur des articles

Nous examinons aussi, à l'aide d'un histogramme de la page de l'article, la distribution de la position des articles sur le secret bancaire. Pour mieux interpréter les résultats de cette analyse,

nous trouvons la longueur du journal pour chaque date et calculons ainsi la position relative de l'article dans le journal. Nous cherchons enfin à voir si des rubriques spécialisées traitent le sujet, en examinant des nuages de points corrélants la date et la page des articles en question. Des ligne horizontales isolées constituerait un indice d'une rubrique permanente.




FIGURE 4 – Nuage de points de la page des articles dans le temps

En comparant le nombre d'article en première page, nous constatons que la fréquence d'une première page pour un article sur le secret bancaire est de 5% dans la *GDL* et 6% dans le *JDG*. Alors que la fréquence d'une première page pour un article générique financier est de 2% pour la *GDL* et 3% pour la *JDG*.

## Analyse des auteurs

La méta-donnée la plus importante après la date qui est traitée en haut est l'auteur d'un article. Nous analysons deux catégories d'auteurs.

### Agences de presse

Beaucoup d'articles de journal proviennent d'agences de presse externes à la rédaction. Nous classifions les articles des agences suivantes :

- ATS : Agence télégraphique suisse
- AFP : Agence France-Presse
- Reuters
- AP : Associated press

Ainsi nous trouvons que pour les articles du secret bancaire le taux d'articles issus d'agences est 10% plus haut que dans le corpus financier.

## Journalistes

Même si l’auteur n’est pas toujours indiqué – surtout dans la première moitié du siècle – nous arrivons à extraire des données sur les journalistes. Au moyen d’une liste de noms d’auteurs<sup>1</sup> et des initiales à la fin de l’article, nous pouvons attribuer des auteurs à plus que 2600 articles.




FIGURE 5 – Articles avec auteur attribué

Cette attribution nous permet de poser les questions suivantes : Est-ce qu’un journaliste est actif dans les deux journaux en même temps ? Est-ce qu’il écrit en moyenne plus souvent sur le secret bancaire que sur d’autres sujets ?

Comme exemple, nous voyons que les deux auteurs du *JDG* qui ont écrit le plus sur le secret bancaire sont Jean-Luc Lederrey (41 articles) et Jacques-Simon Eggly (29 articles). Les deux sont aussi actifs dans la *GDL* et cela même avant la fusion des rédactions en 1991. En plus, une recherche LinkedIn ou Wikipédia révèle que les deux travaillaient aussi dans le monde bancaire<sup>2</sup> ou dans la politique libérale<sup>3</sup>.

## Analyse du contenu

L’analyse de contenu se limite au corpus “secret bancaire”. Dans un premier temps nous produisons des graphiques d’analyses de similitudes pour les deux journaux.

En regardant le résultat on voit que les mots qui apparaissent souvent avec “secret bancaire” dans les textes de la *GDL* et du *JDG* sont différents. Pour la *GDL* on voit des mots tels que “affaire” qui apparaissent et qu’on ne voit pas dans le résultat avec le *JDG*.

Afin de rendre les visuels utilisables, nous affichons ici seulement 40 mots (autres que préposition et déterminants). Afin de ne pas surcharger l’image, seuls les termes qui apparaissent plus de 50

1. Cette liste était obtenue de la page [Wikipédia du Journal de Genève](#).

2. [Jean-Luc Lederrey sur LinkedIn](#).

3. [Jean-Simon Eggly sur Wikipédia](#).



de voir qu’entre les deux journaux le vocabulaire employé est plus variable dans la gazette de Lausanne.

Avec ces informations, nous pouvons déjà observer que le style d’écriture des articles est différent. Nous observons par exemple que la *GDL* semble mettre ensemble des articles qui parlent de secret bancaire avec des articles qui parlent d’affaires judiciaires (avec les mots “secret”, “bancaire” proche du mot “judiciaire”).

## Critique et difficultés

Notre analyse est particulièrement perturbée par les problèmes de l’OCR de basse qualité. Car, les termes que nous tentons d’isoler sont plutôt long et une erreur de reconnaissance est bien plus probable.

Un autre problème est que le format de reconnaissance des articles est assez limité. Il a fallu que nous allions chercher le nom des auteurs manuellement, cependant nous avons observé que mettre le nom de l’auteur sur un article de journal ne devient courant qu’à partir des années 60, limitant nos capacité d’analyse avant cette période.

Nous avons réussi à contourner ce problème en utilisant une liste de noms de journalistes ayant travaillé pour le *JDG*. Cependant nous n’avons pas trouvé une telle liste pour la *GDL*.




FIGURE 8 – AFC de la Gazette de Lausanne




FIGURE 9 – AFC du journal de Genève